

Выполнили:

Каркешкина Екатерина 2402

Лопатин Клим 2409

Панкрашкина Анастасия 2409

Селиванова Екатерина 2402

Углина Валерия 2409

Юлдашев Андрей 2409



Анализ А/В тестирования и открытие первого бара в Москве или Санкт-Петербурге





Часть 1. А/В тестирование

Анализ датасета с АВ тестированием



У нас есть датасет `data_ab` некой компании из сферы образования.

Изначально DataSet состоит из 294478 записей с таким разделением на группы:

count		count	
group		landing_page	
treatment	147276	old_page	147239
control	147202	new_page	147239

Мы видим, что группы неравномерны, получается, что не все пользователи были определены в верные группы.


Целевая метрика - значение “converted”.

Обработка ошибок




1. Удаляем пользователей, которые находятся не в той группе или не с тобой страницей
2. Удаляем дубликаты (находятся в двух разных группах)
3. Удаляем оба значения пользователя, который побывал на странице дважды (такой 1)


Процент ошибок за день



Процент ошибок по дням недели



Процент ошибок по часам



А что там у нас с А/А?

Не проводим. Почему?

А/А тест проводится для того, чтоб проверить, что сплит-система подбирает одинаковые группы. Для его проведения нам нужны две независимые выборки, опирающиеся на исторические данные, но у нас нет таковых, а также мы не знаем что будет с метрикой, если пользователям обеих групп дать старую версию сайта, поэтому провести А/А тестирование мы не можем.

Мы провели анализ зависимости результатов в группах от времени (часы, дни недели, даты).

Итог: выборки по всем параметрам имеют одинаковые распределения, что говорит нам о том, что выборки являются репрезентативными, следовательно А/В тест в данном случае объективен





Немного подробнее о распределениях времени/дня недели/дня посещения в разных группах

H₀ - выборки имеют одно и тоже распределение

H₁ - выборки имеют разное распределение

Воспользуемся критерием Колмогорова-Смирнова: он сравнивает два распределения.

- 1) Час посещения: p-value равен **0,87** что говорит нам о том, что мы не можем опровергнуть гипотезу о том, что данные имеют одинаковое распределение
- 2) День недели: p-value равен **0,99**, что тоже нам говорит о том что мы не отрицаем гипотезу о том, что данные одинаково распределены
- 3) Время посещения: p-value равен **0,65** что говорит нам о том, что мы не можем опровергнуть гипотезу о том, что данные имеют одинаковое распределение
- 4) Дата посещения: p-value равен **0,76** что говорит нам о том, что мы не можем опровергнуть гипотезу о том, что данные имеют одинаковое распределение

Итог: выборки репрезентативные => A/B тест объективен



A/B тест

H₀: конверсия пользователей не зависит от версии страницы

H₁: конверсия на новой странице выше конверсии на старой странице

Проведем Z-тест, так как:

- большая выборка ($n > 30$) и имеет биномиальное распределение => ИТМЛ
- нужно сравнить пропорцию выборки с известной пропорцией
- данные состоят из двух возможных исходов (converted=0 или =1) - биномиальное распределение

p_value 0.89, мы не можем отвергнуть нулевую гипотезу, так как значение p_value > 0.05


Тогда перейдем к методу Bootstrap.



Bootstrap & Монте-Карло 🐼

Наше предположение: конверсия_новая = конверсия_старая = $p = 0.11$

Воспользуемся методом Монте-Карло. Многократно проведем эксперименты для старой и новой страниц. Мы создаем "псевдо" пользователей. Каждый пользователь с вероятностью p совершает действие на странице и с вероятностью $(1 - p)$ не совершает действие на странице



1. 3000 раз генерируем случайную выборку для старой версии страницы с нашими вероятностями p и $1-p$ для совершил наш пользователь действие или нет соответственно.
2. То же самое 3000 раз генерируем случайную выборку для новой версии.
3. Считаем разницу в долях конверсии в типах страниц.

Итог: $p_value > 0.05 \Rightarrow$ не отклоняем H_0

Выводы:

Доверительный интервал $(-0.002462952770803831, 0.002414591638633801)$

В доверительный интервал входит 0, поэтому нет статически значимой разницы между страницами, то есть мы не можем сделать вывод, какая хуже, лучше или они одинаковые.

Итог:

- $p_value > 0.05$ в обоих тестах, не можем отклонить нулевую гипотезу
- Изначальная разница между средними конверсиями новой и старой страниц - отрицательная
- Три возможных реальности:


Реальность 1: Новая страница немного хуже (до -0.246%)

Реальность 2: Страницы одинаковы (разница 0%)

Реальность 3: Новая страница немного лучше (до $+0.241\%$)

Новую страницу не стоит внедрять

Скользящее окно



Итог: new_page не лучше old_page



	Часть суток	Разница	p_value	p_value < 0.05
0	Утро	-0.003664	0.948839	False
1	День	-0.001463	0.709574	False
2	Вечер	0.004732	0.037486	True
3	Ночь	-0.003711	0.952704	False

	Выходной	Разница	p_value	p_value < 0.05
0	0	-0.000800	0.714241	False
1	1	-0.003282	0.921179	False

	Праздники	Разница	p_value	p_value < 0.05
0	0	-0.001413	0.801693	False
1	1	-0.001535	0.809474	False

Байесовский подход к A/B тестированию

Конверсия контрольной группы: **12,03%**

Конверсия экспериментальной группы: **11,88%**


По конверсиям мы видим, что новый сайт не лучше старого


Идея: мы выражаем свои предположения на основе фактических наблюдений, а не через p-value.

То есть мы считаем с какой вероятностью Treatment лучше Control

Вероятность превосходства Treatment над Control: **11,13%**

Мы провели 500 симуляций для того, чтобы понять, что наша симуляция надежна и устойчива. Средняя вероятность превосходства получилась равна 11,15%.
Распределение вероятностей превосходства разбросано в промежутке 11-12%





**НУ ДАВАЙ, РАССКАЖИ
МНЕ,**



**АЛКОГОЛЬ УБИВАЕТ
НЕРВНЫЕ КЛЕТКИ**

**Часть 2.
Открытие бара**

**КАК ПОЛЕЗЕН АЛКОГОЛЬ
В МАЛЫХ ДОЗАХ**

**ОСТАЮТСЯ ОДНИ
СПОКОЙНЫЕ**

Запрос заказчика:

Клиент хочет открыть первую точку сети баров в Москве или Санкт-Петербурге с минимальными затратами. При этом у него нет понимания о том, какое местоположении баров и масштаб будут наиболее удачны.



Цель:

Разработать комплексное бизнес-обоснование выбора места для запуска сети баров.

Сбор данных:

С помощью библиотеки Selenium были извлечены данные об аренде коммерческих помещений по Москве и Санкт-Петербургу с сайта [N1](#)* и сформированы в датасет df_rent.

С использованием нескольких API ключей были извлечены данные о барах с сайта 2ГИС* в этих городах и сформированы в датасет df_bars, а также добыли дополнительную информацию о координатах метро, необходимую для дальнейшего анализа.

Также были извлечены данные об оценках заведений с сайта OpenStreetMap*.



В итоге мы получили:

Датасет `df_rent`, который содержит данные об объявлениях об аренде помещений. После обработки в нем содержится 7649 строк и 18 признаков.


Датасет `df_bars`, который содержит данные о барах в Москве и Питере. После обработки в нем содержится 3054 строки и 20 признаков

Когда заплатил аренду, и теперь у тебя есть место, где голодать:




Анализ df_rent:

Гораздо больше помещений имеют маленькие/ниже среднего размеры (<200 кв м). Более популярны для аренды универсальных помещений меньшие по площади (под офисы, пвз, небольшие кафе, бары и тд).




Анализ df_rent:

Большинство объектов имеют арендную ставку до 500 000 рублей в месяц. Пик графика в диапазоне 100 000 - 300 000 рублей в месяц. Это обусловлено тем, что большее количество помещений имеют небольшую площадь.



Анализ df_rent:

Средняя цена аренды -
до 4000 р/м².



Структура рынка коммерческой недвижимости по типам помещений:

Универсальное помещение:
63.1% (доминирующий
сегмент), торговая площадь:
29.4% (второй по значимости),
помещение под
бар/ресторан: 7.5% (нишевый
сегмент). (Остальные типы
помещений не извлекались, т.
к не соответствуют запросу
клиента)



Анализ df_rent:


Было произведено разбиение всех арендных помещений на 5 группы по размеру: маленькая(до 50 кв м, 21,6%) средняя(от 50 до 120 кв м, 34,7%), большая(от 129 до 300, 28.0%), крупная(от 300 до 600, 10,7%) и очень крупная(600+, 4,9%).

Распределение типов площадей



Анализ df_bars

- районы со скоплением баров с высокими рейтингами: сильная конкуренция, высокий спрос -> проблематично.
- мало баров, а у них низкие рейтинги -> неплохой район



Гипотеза 1

Н0: Между расстоянием до ближайшего метро и ценой аренды за квадратный метр отсутствует статистически значимая зависимость.

Н1: Между расстоянием до ближайшего метро и ценой аренды за квадратный метр существует отрицательная зависимость:

чем ближе помещение к метро, тем выше цена за квадратный метр.

Если гипотеза верна, то стоит задуматься о том, чтобы выбирать помещение, расположенное не слишком близко к метро.





Анализ гипотезы 1

1. Критерий Шапиро-Уилка показывает, что данные распределены ненормально (для Москвы и Питера), и мы имеем дело с numeric data и измеряем relationship между multiple variables, сл - но применим корреляцию spearman
2. Критерий Спирмена: В обоих случаях: $p\text{-value} < 0.05$. Нулевая гипотеза (H_0) отвергается и для Москвы, и для Санкт-Петербурга.

Знак и величина коэффициента Спирмена:

Москва: $|\text{statistic}| \sim 0.29$ - умеренная отрицательная связь

СПб: $|\text{statistic}| \sim 0.17$ - слабая отрицательная связь

Вывод: чем ближе помещение к метро, тем выше цена за квадратный метр. Эффект есть в обоих городах, но сильнее выражен в Москве. Так как наш бар должен быть доступен для посетителей, помещения не должны располагаться очень далеко от станций общественного транспорта. Но при выборе помещений необходимо учесть выводы из этой гипотезы

Гипотеза 2

H₀: в москве чеки не больше чем в питере

H₁: в москве чеки больше чем в питере



Используем тест Манна-Уитни, потому что данные разделены на две группы и имеют численные значения

Итак, согласно результатам теста мы получили $p\text{value} < 5\%$ и следовательно отвергаем нулевую гипотезу, следовательно чеки в Москве статистически значимо выше, чем в Питере

Гипотеза 3

Н₀: между количеством баров в районе и средней оценкой баров в районе нет связи

Н₁: чем меньше баров в районе, тем выше средняя оценка

Для начала мы проверили распределение для каждого города (Москва, Санкт-Петербург) на parametric с помощью теста Шапиро и qqplot - получили, что они распределены нормально. Затем, с помощью теста Пирсона проверили гипотезы и получили $pvalue > 5\%$. Следовательно мы не отклоняем нулевую гипотезу и принимаем, что между кол-вом баров в районе и средней оценкой нет связи



Гипотеза 4

Мы хотим понять, как цена за квадратный метр коммерческой недвижимости связана с размером, то есть площадью, помещения

Общая гипотеза: Размер помещения влияет на стоимость квадратного метра в аренде

У нас есть разные типы помещений по размеру, поэтому поделим анализ на несколько этапов

Тест 1. Краскала-Уоллиса

Н₀: $M_1 = M_2 = M_3 = M_4 = M_5$, где M_n - это медианная цена за квадратный метр в нашем типе площади в рассматриваемом городе

Н₁: $M_i \neq M_j$, то есть у нас существуют статистически значимые различия в медианах цен между хотя бы одной парой категорий площади в рассматриваемом городе

$p_value < 0.05$, поэтому отклоняем

Н₀, то есть медианные цены в группах точно различаются и возможно есть какая-то зависимость в обоих городах

Тест 2. Спирмена

Н₀: цена за квадратный метр не зависит от площади

Н₁: чем больше площадь помещения, тем ниже цена за квадратный метр

Проверим, что зависимость между ценой и площадью точно есть

Получается, что у нас $p_value < 0.05$, поэтому отклоняем Н₀. Получается, что у нас есть зависимость между площадью помещения и ценой за квадратный метр в обоих городах.

Корреляция отрицательна, поэтому Н₁ верна

Тест 3. Критерий Данна

Для каждой пары у нас есть гипотезы:

Н₀: предположение об отсутствии эффекта или различий

Н₁: предположение о наличии эффекта, различия или влияния

Критерий Данна предназначен для попарных сравнений после получения значимого результата критерия Краскела — Уоллиса и позволяет выявить различия между конкретными группами

Москва

	1	2	3	4	5
1	False	True	True	True	True
2	True	False	True	True	True
3	True	True	False	True	True
4	True	True	True	False	True
5	True	True	True	True	False

Санкт-Петербург

	1	2	3	4	5
1	False	True	True	True	True
2	True	False	False	True	True
3	True	False	False	True	True
4	True	True	True	False	True
5	True	True	True	True	False

Вывод для Москвы:

- каждая категория имеет уникальную ценовую позицию
- цена за м² последовательно снижается с увеличением площади

Тогда арендаторам в Москве не выгодно арендовать маленькие помещения

Вывод для Питера:

- средняя и большая площади находятся в одной ценовой политики
- цена за м² последовательно снижается с увеличением площади

Тогда арендаторам в Питере не выгодно арендовать маленькие и средние помещения

Гипотеза 5

Проверяем гипотезу о том, что в Москве цена за кв. метр больше, чем в Питере, тогда

H₀: в москве цена за квадратный метр не больше чем в питере

H₁: в москве цена за квадратный метр больше чем в питере

Используем тест Манна-Уитни, потому что данные разделены на две группы и имеют численные значения.

После применения данного теста получили, что отвергаем **H₀**: цена за квадратный метр в Москве статистически значимо выше, чем в Питере ($p\text{value} < 5\%$)


Выводы после проверки гипотез

1. Мы рассматриваем помещения, которые находятся на расстоянии чуть выше среднего (50-60% от ср. знач) от метро. Потому что близко к метро дорого, а далеко - неудобно для посетителей
2. Средний чек в москве выше, чем в Санкт-Петербурге
3. Мы ничего не можем сказать про зависимость средней оценки от количества баров в районе
4. Нужно рассматривать более крупные помещения, но т.к. это первая точка мы не будем рассматривать очень крупные помещения, а сосредоточимся на крупных и больших
5. В питере квадратный метр дешевле, чем в Москве


Можно сделать вывод, что лучше выбирать помещение в Питере, находящееся на среднем расстоянии от метро, по размеру оно должно быть большим или крупным

Самые благоприятные районы СПб

	district	postcode_3	reviews.general_rating	
			mean	count
0	Сенной округ	190	4.376000	25
1	округ Малая Охта	195	4.404348	23
4	Балканский округ	192	4.513889	36
6	округ Светлановское	194	4.589189	37
8	Адмиралтейский округ	190	4.700000	34



Идеальное помещение по нашим критериям



Параметры

Общая площадь	250 м ²
Этаж	1
Отдельный вход	есть
Год постройки	1973

Назначение помещения


Магазин, выставочный зал, кафе, бар, ресторан, склады, хранение товаров

Сдам универсальное помещение, Купчинская, 15 корп. 1

24 июня Обн. 14 дек 8 (+4)

180 000 Р в месяц

720 Р/м² в месяц



ул. Купчинская · Фрунзенский район · Санкт-Петербург

Внешний пользователь

Татьяна Геннадьевна


Татьяна Геннадьевна

+7 981 226-XX-XX

Показать телефон

Написать сообщение

Идеальное помещение по нашим критериям




Сдам универсальное помещение, Купчинская, 32 корп. 1д

19 ноя Обн. сегодня 1 (+1)

350 000 ₽ в месяц

1000 ₽/м² в месяц



ул. Купчинская · Фрунзенский район · Санкт-Петербург

350 м²
общая
2
этаж

Внешний пользователь

Мир Квартир PREMIUM

Сергей Санжаров

+7 981 280-XX-XX

Показать телефон

Написать сообщение

Выводы анализа:

- Выбран город для открытия 1 бара - Санкт-Петербург
- Предложен пул вариантов конкретных объявлений для открытия 1 бара в Санкт-Петербурге.



Спасибо за внимание